

# Que faire avec un neurone ?

Collonville Thomas

Version 0.1.0-SNAPSHOT, 20/11/2018

# Plan

1. Sommaire .....	1
2. Qu'est ce que l'IA .....	1
3. Historique .....	1
3.1. Historique .....	2
4. Les modeles .....	2
4.1. Non-supervisé .....	2
4.2. Supervisé .....	2
5. Le neurone .....	2
5.1. Le neurone biologique .....	2
5.2. Constitution .....	3
5.3. Quelques nombres .....	3
5.4. Utilité .....	3
5.5. Le neurone formel .....	3
5.6. Le neurone formel .....	4
5.7. La fonction d'activation .....	4
5.8. Lineaire .....	4
5.9. Sigmoire .....	5
5.10. Limiteur .....	5
6. Processus .....	6
7. Exemples .....	6
8. Probleme de tri .....	6
8.1. Les données .....	6
8.2. Les données .....	7
8.3. Les données .....	7
8.4. Profil moyen .....	8
9. La classification lineaire .....	8
9.1. Solution adhoc .....	8
9.2. Pourquoi ca marche .....	9
9.3. Solution logicielle .....	9
9.4. Mesure de la performance .....	9
9.5. Superposition .....	10
9.6. Matrice de confusion .....	10
9.7. Interpretation .....	10
9.8. Precision et rappel .....	11
9.9. Apprentissage .....	11
9.10. Apprentissage .....	11
9.11. Test de l'apprentissage .....	11
9.12. Test de l'apprentissage .....	12

10. La classification sigmoïde .....	12
10.1. Modèle Sigmoïde .....	12
10.2. Résultat .....	13
10.3. Interprétation .....	13
11. La régression linéaire .....	13
11.1. Problématique .....	13
11.2. Estimateur .....	14
11.3. Inférence .....	14
12. Conclusion .....	14




Ou un peu d'espoir pour certains d'entre nous...

# 1. Sommaire

- Qu'est ce que l'IA
- Historique
- Le neurone
- Processus de traitement
- Exemple

## 2. Qu'est ce que l'IA



## 3. Historique

- 1940 : Alan TURING : Machine de Turing
- 1943 : Warren McCULLOCH & Walter PITTS Modèle formel de neurone.
- 1949 : Donald HEBB : Mémoire associative, premières règles d'apprentissage.
- 1960 : Franck ROSENBLATT et Bernard WIDROW, Perceptron et Adaline.
- 1980 : Stephen GROSSBERG et Teuvo KOHONEN Auto-organisation des réseaux et adaptation

## 3.1. Historique

- 1986 : Paul Smolenski : Machine de BOLTZMANN
- 1997: Deep Blue
- 2011 : Watson
- 2014 : LeCun Deep Learning
- 2015 : Alpha Go
- 2018 : Alexa

## 4. Les modeles

### 4.1. Non-supervisé

- Foret aléatoire
- Clustering et réduction de dimension
- SVD
- Analyse par composante principale (a noyau ou non)
- Règles


### 4.2. Supervisé

- Régression linéaire ou logistique
- Descente de gradient
- Régression polynomiale
- Séparation a vaste marge (SVM)
- Arbre de descision
- Classification linéaire ou non linéaire
- Réseau de neurone
- Naïve bayes

## 5. Le neurone

- Outil mathématique
- Formalisé par McCULLOCH et PITTS

### 5.1. Le neurone biologique



## 5.2. Constitution

- d'un noyau : le cœur de la cellule neuronale
- de dendrites permettant d'agréger les informations entrantes venant des synapses
- d'axones fournissant la réponse neuronale
- de synapses : interconnexion entre les axones et les dendrites permettant le transfert de l'influx nerveux

## 5.3. Quelques nombres

- 100 Milliards de neurones
- 10000 Synapses par neurone
- $10^{15}$  Synapses dans le cerveau humain

## 5.4. Utilité

- Mémoire et persistance des données dans le temps
- Réflexion, élaboration des idées, associer des concepts et des stratégies
- Sens, Analyse des données, traitements des sons, des images, du touché
- Construction d'une réponse moteur, l'équilibre, l'orientation, la marche, dextérité

## 5.5. Le neurone formel

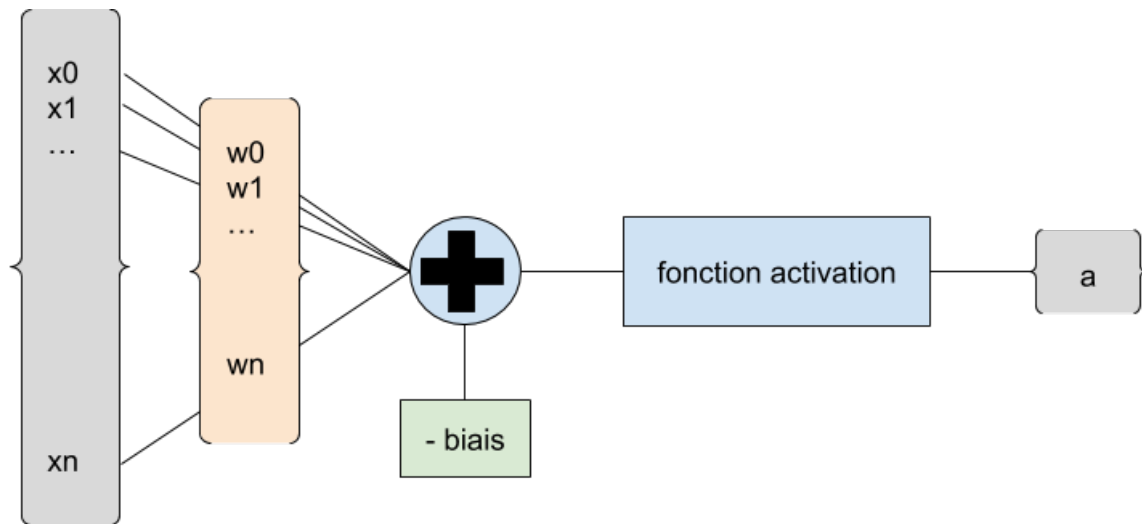
$$a = f(\sum_i^n (x_i \cdot w_i) - b)$$

$$a = f(W^T \cdot X - b)$$

- a la sortie du neurone


- $x_i$ , le signal d'entrée
- $w_i$ , le poids de pondération
- biais, une constante de pondération
- $f$ , la fonction d'activation

## 5.6. Le neurone formel




## 5.7. La fonction d'activation


### 5.8. Lineaire



## 5.9. Sigmoire



## 5.10. Limiteur





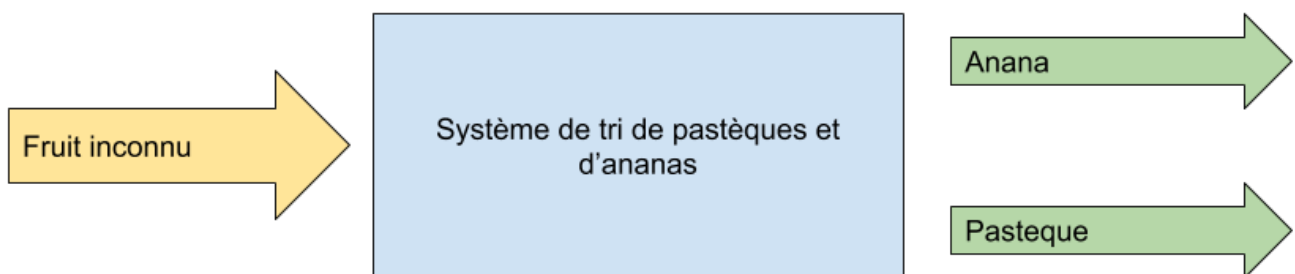
## 6. Processus

- Analyse du probleme
  - Nettoyage des données
  - Visualisation des données
  - Jeux de test
  - Jeux d'entraînement
- Definition d'un modele
- Apprentissage
- Mesure d'efficacité
- Mise en exploitation

## 7. Exemples

- Problemes de classification
- Approche Linéaire
- Approche Sigmoïde
- Probleme de regression
- Approche Linéaire

## 8. Probleme de tri



- a rugosité → 0 lisse a 1 rudeux
- la couleur → 0 bleu a 1 rouge
- la forme → 0 rond a 1 alongé
- le poid → 0 (20gr) à 1 (2000gr)

### 8.1. Les données





```
def generateSet(prototype,nbrEchantillon,coef):
    rand_value=np.random.randn(len(prototype),len(prototype[0]))/coef
    #print(rand_value)
    rand_set=prototype+rand_value
    if nbrEchantillon == 0 :
        return prototype
    else:
        return np.concatenate((rand_set,generateSet(prototype,nbrEchantillon-1,coef)))
```

## 8.2. Les données

```
pasteque=np.array([[0.2, 0.3, 0.2, 0.95]])
anana=np.array([[0.8, 0.65, 0.6, 0.8]])

pasteques=generateSet(pasteque,1999,10)
ananas=generateSet(anana,1999,10)
# 10 -> pour separer les ensembles
```

## 8.3. Les données



## 8.4. Profil moyen





pastèque [0.2, 0.3, 0.2, 0.95]  
anana [0.8, 0.65, 0.6, 0.8]

# 9. La classification lineaire

## 9.1. Solution adhoc

- $W=[1;1;1;0]$
- biais 1,5
- Verification analytique
  - $\text{limiteur}((Wt.\text{pasteque})-\text{biais})= \text{limiteur}(0.4-1.5)= \text{limiteur}(-1.1) = 0$
  - $\text{limiteur}((Wt.\text{anana})-\text{biais})= \text{limiteur}(2.35-1.5)= \text{limiteur}(0.85) = 1$

## 9.2. Pourquoi ça marche



## 9.3. Solution logicielle

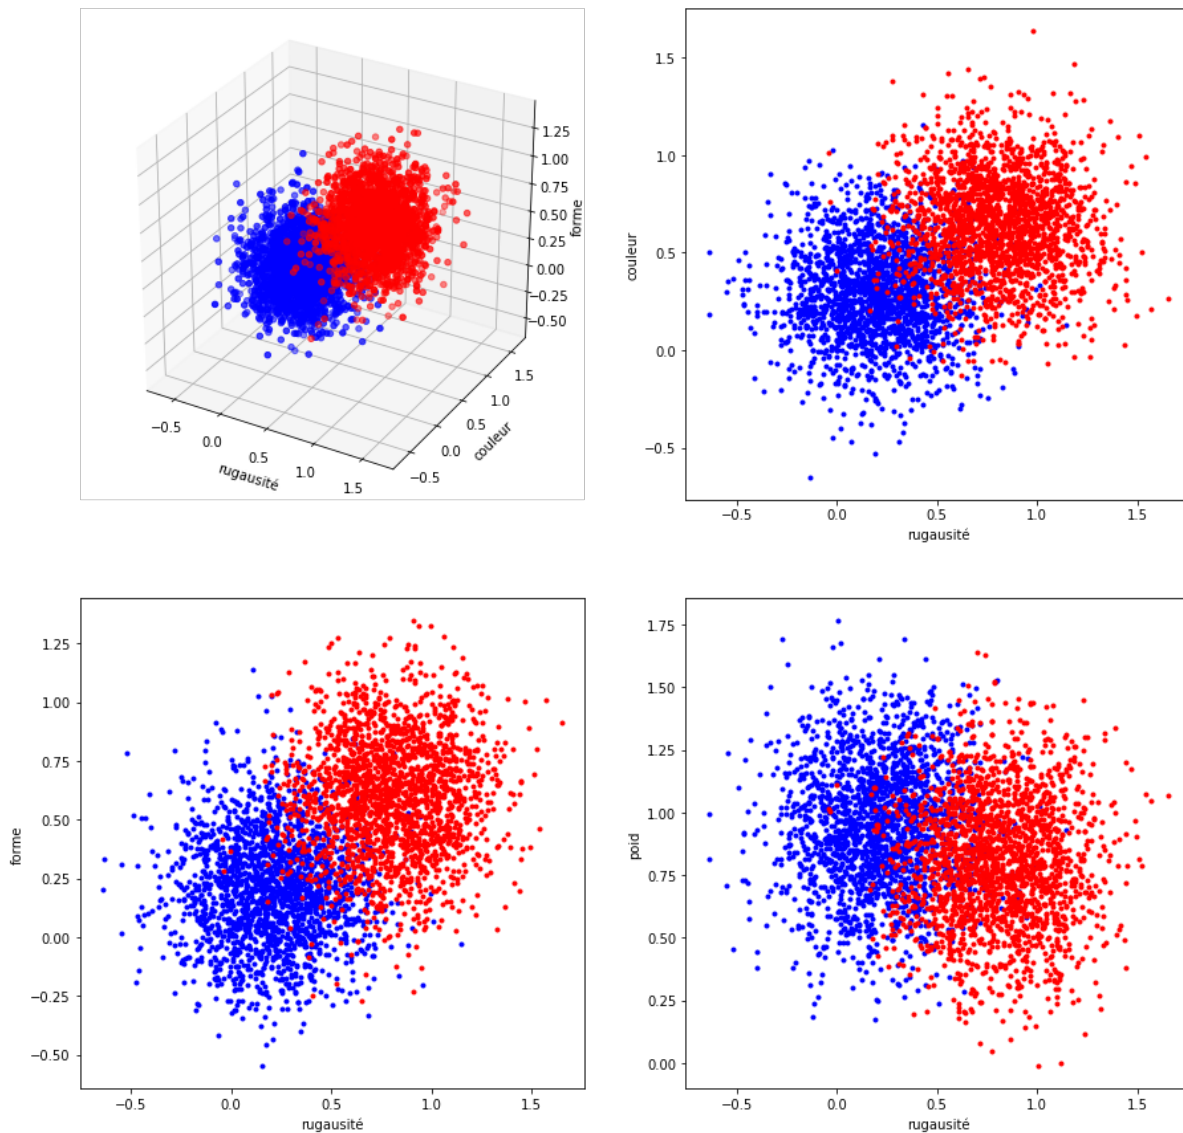
```
def neuroneLim(entre,W,biais):  
    a=np.dot(entre,W.T)-biais  
    #print("a neurone:",a)  
    if a > 0:  
        return 1  
    return 0
```

## 9.4. Mesure de la performance

- Calcul du cout
  - Ratio des bonnes reponses par rapport au mauvaise
- pasteques: 71 somme: 96.49824912456228

- ananas: 1815 somme: 90.79539769884943

## 9.5. Superposition



Outil plus précis?

## 9.6. Matrice de confusion

$$\begin{pmatrix} \text{reel / prediction} & \text{pastèques} & \text{ananas} \\ \text{pastèques} & 1938 & 62 \\ \text{ananas} & 202 & 1798 \end{pmatrix}$$

## 9.7. Interpretation

- 1938 Vrai Positif
- 1798 Vrai Négatif
- 62 Faux Négatif
- 202 Faux Positif

## 9.8. Precision et rappel

- Précision :  $VP/(VP+FP) = 1938/(1938+202) = 0.90$ 
  - capacité à détecter des pastèques en présence d'ananas
  - 0.90 de chance que le modèle réponde que le fruit est un ananas
- Rappel ou sensibilité :  $VP/(VP+FN) = 1938/(1938+62) = 0.97$ 
  - capacité à réellement détecter une pastèque dans un ensemble ne contenant que de pastèques

## 9.9. Apprentissage

- supervisés → on indique la bonne réponse
- non supervisé → le modèle interprète la réponse (approche par clustering)
- semi-supervisé

```
si etiquete - sortie > 0 alors W=W+data
si etiquete - sortie < 0 alors W=W-data
si etiquete - sortie = 0 alors W
```

## 9.10. Apprentissage


```
def majW(W, sortie, etiquete, entree):
    return W+(etiquete-sortie)*entree

for (val, etiquete) in datasApprentissage:
    sortie=neuroneLim(val, W, biais)
    W=majW(W, sortie, etiquete, val)
```

## 9.11. Test de l'apprentissage

```
for (val, etiquete) in datasTest:
    sortie=neuroneLim(val, W, biais)
    #print(sortie, etiquete)
    if sortie != etiquete:
        erreur.append(erreur[len(erreur)-1]+1)
    else:
        erreur.append(erreur[len(erreur)-1])
```

## 9.12. Test de l'apprentissage



## 10. La classification sigmoïde


### 10.1. Modèle Sigmoïde

```
def neuroneCore(entre,W,biais):  
    return np.dot(entre,W.T)-biais  
  
def sigmoid(a):  
    return 1 / (1 + math.exp(-a))  
  
def neuroneSig(entre,W,biais):  
    a=neuroneCore(entre,W,biais)  
    return sigmoid(a)
```

## 10.2. Resultat

- 15 données indécidables
- 471 pastèques qui sont bien des pasquettes!
- 452 ananas qui sont bien des ananas!
- 40 pastèques qui se prennent pour des ananas
- 22 ananas qui se prennent pour des pastèques

## 10.3. Interpretation



## 11. La regression lineaire

### 11.1. Problematique

[800] | *donneesBruite.png*



## 11.2. Estimateur

$$\hat{y} = W^T.X + b$$

Equation Normale

$$\Theta = (X^T.X)^{-1}.X^T.Y$$

## 11.3. Inference

```
public Double linearInfer(Double[] stepInputs)
{
    Stream.Builder<Double> sum=Stream.<Double>builder();
    for(int i=0;i<dendrites.length;i++)
    {
        if(i<stepInputs.length)
            sum.add(dendrites[i]*stepInputs[i]);
        else
            sum.add(dendrites[i]);
    }
    return sum.build().reduce((x,y)-> x+y).get();;
}
```

## 12. Conclusion